



دانشگاه صنعتی امیرکبیر

(پلی تکنیک تهران)

دانشکده ریاضی و علوم کامپیوتر

پروژه کارشناسی

به کارگیری روش های مبتنی بر یادگیری ماشین بر روی
دیتاست بیماری های قلبی و عروقی

نگارش

علیرضا محمدزاده

استاد راهنما

دکتر مهدی قطعی

بهمن ۱۴۰۳

بِسْمِ اللَّهِ الرَّحْمَنِ الرَّحِيمِ

صفحه فرم ارزیابی و تصویب پایان نامه - فرم تأیید اعضاء کمیته دفاع

در این صفحه فرم دفاع یا تأیید و تصویب پایان نامه موسوم به فرم کمیته دفاع - موجود در پرونده آموزشی - را قرار دهید.

نکات مهم:

- نگارش پایان نامه/رساله باید به **زبان فارسی** و بر اساس آخرین نسخه دستورالعمل و راهنمای تدوین پایان نامه های دانشگاه صنعتی امیرکبیر باشد.(دستورالعمل و راهنمای حاضر)
- رنگ جلد پایان نامه/رساله چاپی کارشناسی، کارشناسی ارشد و دکترا باید به ترتیب مشکی، طوسی و سفید رنگ باشد.
- چاپ و صحافی پایان نامه/رساله بصورت **پشت و رو(دورو)** بلامانع است و انجام آن توصیه می شود.



دانشگاه صنعتی امیرکبیر
(پلی تکنیک تهران)

به نام خدا

تعهدنامه اصالت اثر

تاریخ: بهمن ۱۴۰۳

اینجانب **علیرضا محمدزاده** متعهد می‌شوم که مطالب مندرج در این پایان‌نامه حاصل کار پژوهشی اینجانب تحت نظارت و راهنمایی اساتید دانشگاه صنعتی امیرکبیر بوده و به دستاوردهای دیگران که در این پژوهش از آنها استفاده شده است مطابق مقررات و روال متعارف ارجاع و در فهرست منابع و مآخذ ذکر گردیده است. این پایان‌نامه قبلاً برای احراز هیچ مدرک هم‌سطح یا بالاتر ارائه نگردیده است. در صورت اثبات تخلف در هر زمان، مدرک تحصیلی صادر شده توسط دانشگاه از درجه اعتبار ساقط بوده و دانشگاه حق پیگیری قانونی خواهد داشت.

کلیه نتایج و حقوق حاصل از این پایان‌نامه متعلق به دانشگاه صنعتی امیرکبیر می‌باشد. هرگونه استفاده از نتایج علمی و عملی، واگذاری اطلاعات به دیگران یا چاپ و تکثیر، نسخه‌برداری، ترجمه و اقتباس از این پایان‌نامه بدون موافقت کتبی دانشگاه صنعتی امیرکبیر ممنوع است. نقل مطالب با ذکر مآخذ بلامانع است.

علیرضا محمدزاده

امضا

سپاس‌گزاری

بدین‌وسیله مراتب سپاس و قدردانی خود را از جناب آقای دکتر مهدی قطعی، استاد راهنمای محترم، به خاطر راهنمایی‌ها و حمایت‌های بی‌دریغشان در طول انجام این پروژه ابراز می‌دارم. همچنین از جناب آقای دکتر بهنام یوسفی به خاطر کمک‌ها و راهنمایی‌های ارزشمندشان در طول این پژوهش صمیمانه تشکر می‌کنم. بدون کمک و حمایت‌های این عزیزان، انجام این پژوهش میسر نمی‌گردید.

علیرضا مهرزاده

بهمن ۱۴۰۳

چکیده

در این پروژه، به بررسی و بهبود عملکرد مدل‌های یادگیری ماشین بر روی دیتاست بیماری‌های قلبی عروقی^۱ پرداخته‌ایم. مدل‌های درخت تصمیم^۲، جنگل تصادفی^۳ و XGBoost پیش‌تر بر روی این دیتاست اجرا شده بودند. هدف این پروژه پیاده‌سازی یک مدل شبکه عصبی چندلایه^۴ و بهینه‌سازی ابرپارامترهای آن با استفاده از الگوریتم ژنتیک بوده است. نتایج نشان می‌دهد که بهینه‌سازی ابرپارامترها با استفاده از الگوریتم ژنتیک می‌تواند به بهبود عملکرد مدل شبکه عصبی چندلایه در پیش‌بینی بیماری‌های قلبی عروقی کمک کند.

واژه‌های کلیدی:

بیماری‌های قلبی عروقی، شبکه عصبی چندلایه، الگوریتم ژنتیک، بهینه‌سازی ابرپارامترهای شبکه عصبی

¹Cardio Vascular Diseases - CVD

²Decision Tree

³Random Forest

⁴Multi Layer Perceptron - MLP

فهرست مطالب

عنوان

صفحه

۱	فصل اول مقدمه	۲
۱-۱	مقدمه	۳
۲	فصل دوم مروری بر کارهای پیشین و مفاهیم مرتبط	۵
۱-۲	درخت تصمیم (Decision Tree)	۶
۱-۱-۲	مقدمه	۶
۲-۱-۲	۱. مفاهیم پایه‌ای درخت تصمیم	۶
۳-۱-۲	۲. معیارهای تقسیم‌بندی در درخت تصمیم	۶
۴-۱-۲	۳. مزایا و معایب درخت تصمیم	۷
۵-۱-۲	۴. راه کارهای بهینه‌سازی درخت تصمیم	۸
۲-۲	جنگل تصادفی (Random Forest)	۹
۱-۲-۲	مقدمه	۹
۲-۲-۲	۱. چگونه جنگل تصادفی کار می‌کند؟	۹
۳-۲-۲	۲. مزایای جنگل تصادفی	۱۱
۳-۲	XGBoost	۱۲
۱-۳-۲	مقدمه	۱۲
۲-۳-۲	۱. چگونه XGBoost کار می‌کند؟	۱۲
۳-۳-۲	۲. چرا XGBoost محبوب است؟	۱۳
۳	فصل سوم بهینه‌سازی ابرپارامترهای MLP به کمک الگوریتم ژنتیک	۱۵
۱-۳	MLP: پرسپترون چند لایه	۱۶
۱-۱-۳	۱. ساختار شبکه MLP	۱۶
۲-۱-۳	۲. فرآیند یادگیری در MLP	۱۷
۳-۱-۳	۳. تابع فعال‌سازی ReLU	۱۸
۴-۱-۳	۴. مزایای ReLU	۱۸
۲-۳	الگوریتم ژنتیک	۲۰

۲۰	۱-۲-۳ مفاهیم پایه‌ای الگوریتم ژنتیک
۲۰	۲-۲-۳ فضای حالت
۲۱	۳-۲-۳ پارامترهای الگوریتم ژنتیک
۲۱	۴-۲-۳ عملکرد الگوریتم ژنتیک
۲۳	۴ فصل چهارم نتایج عددی
۲۴	۱-۴ نتایج عددی و مقایسه روش‌ها
۲۴	۱-۱-۴ مجموعه دادگان
۲۵	۲-۱-۴ معیارهای ارزیابی مدل‌ها
۲۵	۳-۱-۴ تشریح گام‌به‌گام روش پیشنهادی
۲۸	۴-۱-۴ مقایسه عددی و تحلیل نتایج
۲۹	۵ جمع‌بندی و نتیجه‌گیری و پیشنهادات
۳۰	۱-۵ نتیجه‌گیری
۳۰	۲-۵ پیشنهادات
۳۲	منابع و مراجع

فهرست اشکال

صفحه

شکل

۷		توضیح مدل Decision Tree	۱-۲
۱۰		توضیح مدل Random Forest	۲-۲
۱۳		توضیح مدل XGBoost	۳-۲
۱۷		شرح ساختار شبکه MLP	۱-۳
۱۹		شرح تابع فعال سازی ReLU	۲-۳
۲۲		نمودار مراحل الگوریتم ژنتیک	۳-۳

فهرست جداول

صفحه

جدول

۲۸	۱-۴ مقایسه تنظیمات مختلف ابرپارامترها و تأثیر آن بر دقت مدل
۲۸	۲-۴ مقایسه عملکرد مدل‌های مختلف در پیش‌بینی CVD

فصل اول

فصل اول مقدمه

۱-۱ مقدمه

بیماری‌های قلبی عروقی (۱) به یکی از مهم‌ترین بیماری‌ها در سراسر جهان تبدیل شده‌اند و بالاترین نرخ مرگ و میر و ناتوانی را به خود اختصاص داده‌اند، بدون توجه به اینکه کشورها توسعه‌یافته هستند یا خیر. بر اساس گزارش سازمان بهداشت جهانی، این بیماری سالانه باعث مرگ حدود ۱۷.۹ میلیون نفر می‌شود [۱]. به دلیل روند سریع و وخیم شدن این بیماری، بررسی عوامل خطر آن پیچیده شده است. مطالعات بسیاری به صورت آزمایشگاهی (۲)، درون‌بدنی (۳) و شبیه‌سازی (۴) بر روی عوامل خطر بیماری‌های قلبی عروقی انجام شده است. این مطالعات نشان داده‌اند که فشار خون سیستولیک و دیاستولیک با عواملی مانند سیگار کشیدن، پیری، زیرگروه‌های وزنی، کلسترول، سطح گلوکز و مصرف الکل مرتبط هستند [۲]. به دلیل فرآیند پیچیده و گسترده عوامل خطر، تشخیص زودهنگام بیماری‌های قلبی عروقی و مرحله درمان آن به یک ضرورت تبدیل شده است.

در مطالعات اخیر، تکنیک‌های یادگیری ماشین (۵) که می‌توانند تعاملات پیچیده عوامل مرتبط با بیماری را توضیح دهند، به طور فزاینده‌ای در مدل‌های پیش‌بینی استفاده می‌شوند. مطالعات بسیاری با استفاده از روش‌های یادگیری ماشین و یادگیری عمیق (۶) انجام شده است. به عنوان مثال، العارف و همکاران در سال ۲۰۱۸ با استفاده از روش‌های تصویربرداری غیرتهاجمی به مطالعات بیماری‌های قلبی عروقی کمک کردند [۳]، قوش و همکاران در سال ۲۰۲۱ از مدل‌های یادگیری ماشین استفاده کردند [۴]، و آریال و همکاران در سال ۲۰۲۰ از روش‌های مبتنی بر میکروبیوم روده استفاده کردند [۵].

روش‌های هوش مصنوعی قابل توضیح (۷) به عنوان راه‌حلی برای نگرانی‌ها درباره قابلیت توضیح مدل و الگوریتم‌های هوش مصنوعی ظهور کرده‌اند. هوش مصنوعی قابل توضیح اخیراً برای کمک به متخصصان بهداشت و درمان در درک روابط بین مدل‌های یادگیری ماشین و نتایج پیش‌بینی‌شده آن‌ها استفاده شده است. در عین حال، این روش می‌تواند توانایی تفسیر الگوریتم‌ها را بهبود بخشد و دقت پیش‌بینی مدل‌های پیچیده یادگیری ماشین را حفظ کند. در میان مطالعات مربوط به عوامل خطر بیماری‌های قلبی عروقی، مطالعات هوش مصنوعی قابل توضیح کمیاب هستند. در این مطالعه، انتخاب

¹Cardiovascular Diseases - CVD²in vitro³in vivo⁴in silico⁵Machine Learning⁶Deep Learning⁷Explainable Artificial Intelligence - XAI

اهمیت ویژگی و روش‌های هوش مصنوعی قابل توضیح بر روی دیتاست حاوی عوامل خطر بیماری‌های قلبی عروقی استفاده شد. ما اهمیت غالب عوامل خطر بر بیماری‌های قلبی عروقی را با روش استاندارد اهمیت، روش اهمیت ویژگی جایگزین^(۸) و روش هوش مصنوعی قابل توضیح مقایسه کردیم. با استفاده از روش توضیحات افزایی شاپلی^(۹)، عوامل خطری که به طور قابل توجهی بر بیماری‌های قلبی عروقی تأثیر می‌گذارند را شناسایی کردیم [۶]. ما روابط بین بیماری‌های قلبی عروقی و عوامل خطر را با نمودارهای مختلف هوش مصنوعی قابل توضیح آشکار کردیم و دقت مدل قابل توضیح خود را با مقایسه آن با داده‌های ادبیات اثبات کردیم.

هدف این تحقیق بررسی و مقایسه الگوریتم‌های مختلف یادگیری ماشین و یادگیری عمیق برای پیش‌بینی بیماری‌های قلبی عروقی است.

⁸Permutation Feature Importance - PFI

⁹Shapley Additive Explanations - SHAP

فصل دوم

فصل دوم مروری بر کارهای پیشین و مفاهیم

مرتبط

۱-۲ درخت تصمیم (Decision Tree)

۱-۱-۲ مقدمه

درخت تصمیم یک مدل یادگیری ماشین است که به طور گسترده برای مسائل طبقه بندی و رگرسیون استفاده می شود [۷].

۲-۱-۲ ۱. مفاهیم پایه ای درخت تصمیم

درخت تصمیم شامل مجموعه ای از گره ها و شاخه ها است. هر گره نمایانگر یک ویژگی (ویژگی ورودی) است که بر اساس آن تصمیم گیری انجام می شود. هر شاخه نشان دهنده نتیجه یک تصمیم یا دسته بندی بر اساس مقدار ویژگی ها است:

- **گره ریشه:** اولین گره درخت است که در آن تصمیم گیری آغاز می شود و تقسیم بندی اولیه داده ها صورت می گیرد.
- **گره های داخلی:** گره هایی که ویژگی های ورودی را بررسی کرده و داده ها را به گره های بعدی تقسیم می کنند.
- **گره های برگ:** گره هایی که در آن ها نتیجه نهایی تصمیم گیری (کلاس یا مقدار پیش بینی شده) نمایش داده می شود.

۳-۱-۲ ۲. معیارهای تقسیم بندی در درخت تصمیم

برای انتخاب ویژگی که داده ها را تقسیم کند، از معیارهایی استفاده می شود که میزان کیفیت تقسیم را ارزیابی می کنند. این معیارها عبارتند از:


- **گینی^۱**

$$Gini = 1 - \sum_{i=1}^c p_i^2$$

که در آن p_i احتمال نمونه هایی است که متعلق به کلاس i هستند و c تعداد کلاس ها است [۸].

^۱Gini Index

Tree



Decision Tree (آ)

شکل ۱-۲: توضیح مدل Decision Tree

• انتروپی^۲

$$Entropy = - \sum_{i=1}^c p_i \log_2 p_i$$

که در آن p_i همان احتمال تعلق داشتن نمونه به کلاس i است [۷].

• کاهش اطلاعات^۳

$$IG = Entropy_{parent} - \sum_k \frac{|D_k|}{|D|} Entropy_k$$

که در آن D_k مجموعه داده‌های تقسیم شده و $|D_k|$ اندازه هر مجموعه است [۷].

۴-۱-۲. مزایا و معایب درخت تصمیم

مزایا:

²Entropy

³Information Gain

- تفسیرپذیری ساده: درخت تصمیم به صورت گرافیکی نمایش داده می شود و روند تصمیم گیری آن به راحتی قابل درک است [۷].
- عدم نیاز به نرمال سازی داده ها: برخلاف بسیاری از الگوریتم های دیگر، نیازی به مقیاس بندی ویژگی ها ندارد.
- پشتیبانی از ویژگی های عددی و دسته ای: درخت تصمیم قادر است هم داده های عددی و هم داده های دسته ای را پردازش کند.

معایب:

- مستعد Overfitting: اگر درخت بیش از حد پیچیده شود، ممکن است بر داده های آموزشی بیش از حد منطبق شده و دقت آن در داده های جدید کاهش یابد [۹].
- عدم کارایی در مسائل پیچیده: درخت تصمیم به تنهایی ممکن است در مواجهه با مجموعه داده های بزرگ و پیچیده عملکرد ضعیفی داشته باشد.
- حساسیت به نویز: داده های نامتوازن یا دارای نویز می توانند درخت تصمیم را به سمت تقسیم بندی های نادرست سوق دهند.

۲-۱-۵. ۴. راه کارهای بهینه سازی درخت تصمیم

برای بهبود عملکرد درخت تصمیم و کاهش مشکلات آن، روش های زیر استفاده می شود:

- کاهش عمق درخت (۴): دو نوع هرس در درخت تصمیم وجود دارد:
 - هرس پیش گستر (۵): قبل از گسترش کامل درخت، معیارهایی مانند حداقل تعداد نمونه در هر گره را تعیین می کند تا از ایجاد درخت های عمیق و پیچیده جلوگیری شود [۹].
 - هرس پس گستر (۶): ابتدا درخت کامل ساخته می شود و سپس با استفاده از روش هایی مانند کاهش تعداد گره های غیر ضروری، بهینه سازی می شود [۹].
- جنگل تصادفی (۷): استفاده از مجموعه ای از درخت های تصمیم برای ایجاد مدل های قوی تر و

⁴Pruning

⁵Pre-pruning

⁶Post-pruning

⁷Random Forest

کاهش بیش‌برازش [۱۰].

- Gradient Boosting: ترکیب چندین درخت تصمیم به‌طور متوالی برای افزایش دقت مدل [۱۱].

- استفاده از ویژگی‌های مهم: حذف ویژگی‌های غیرضروری که تأثیر کمی بر پیش‌بینی دارند.
- Cross-validation: استفاده از روش اعتبارسنجی متقابل برای ارزیابی عملکرد مدل بر روی مجموعه داده‌های مختلف.

۲-۲ جنگل تصادفی (Random Forest)

۱-۲-۲ مقدمه

جنگل تصادفی یک الگوریتم یادگیری ماشین مبتنی بر روش‌های یادگیری گروهی است که برای طبقه‌بندی و پیش‌بینی داده‌ها استفاده می‌شود. این الگوریتم با ترکیب چندین درخت تصمیم‌گیری، یک مدل قوی‌تر و پایدارتر ایجاد می‌کند که در برابر Overfitting مقاوم‌تر است. [۱۰، ۷، ۱۲]

۲-۲-۲ ۱. چگونه جنگل تصادفی کار می‌کند؟


۱.۱. درختان تصمیم‌گیری در جنگل تصادفی

جنگل تصادفی شامل مجموعه‌ای از درختان تصمیم‌گیری^۸ است که به‌صورت مستقل روی داده‌های ورودی آموزش داده می‌شوند. هر درخت تصمیم‌گیری داده‌ها را با استفاده از یک ساختار سلسله‌مراتبی تقسیم‌بندی کرده و یک پیش‌بینی تولید می‌کند. در نهایت، نتایج تمام درختان برای تصمیم‌گیری نهایی ترکیب می‌شود. درخت تصمیم‌گیری با استفاده از معیارهای مختلف، بهترین ویژگی برای تقسیم داده‌ها را در هر گره انتخاب می‌کند. یکی از این معیارها شاخص جینی^۹ است که برای ارزیابی میزان خلوص یک مجموعه داده استفاده می‌شود. [۱۰]

$$Gini = 1 - \sum_{i=1}^C p_i^2$$

^۸Decision Trees

^۹Gini Index



Random Forest ($\bar{f}$)

شکل ۲-۲: توضیح مدل Random Forest

که در آن:

- p_i نسبت نمونه‌های کلاس i به کل نمونه‌ها در گره است.

- C تعداد کلاس‌ها در داده‌های طبقه‌بندی است.

معیار دیگر، آنترپی^{۱۰} است که مقدار عدم قطعیت را در یک مجموعه داده اندازه‌گیری می‌کند. [۷]

$$Entropy = - \sum_{i=1}^C p_i \log_2 p_i$$

۲.۱ روش Bootstrap Aggregating (Bagging)

جنگل تصادفی از تکنیکی به نام Bagging برای ایجاد مجموعه‌ای از مدل‌های مستقل استفاده می‌کند [۱۳]. در این روش:

- تعداد زیادی زیرمجموعه از داده‌های آموزشی به صورت تصادفی و با جای‌گذاری انتخاب می‌شوند.

¹⁰Entropy

- هر درخت تصمیم‌گیری بر روی یکی از این زیرمجموعه‌ها آموزش داده می‌شود.
- در نهایت، در مرحله‌ی پیش‌بینی، رای‌گیری اکثریت برای طبقه‌بندی و میانگین‌گیری برای مسائل رگرسیون استفاده می‌شود.
- این تکنیک از روش Bootstrap Sampling برای انتخاب تصادفی داده‌ها استفاده می‌کند. [۱۴]
- در طبقه‌بندی، برچسب نهایی به صورت زیر محاسبه می‌شود:

$$\hat{y} = \arg \max_k \sum_{i=1}^N I(h_i(x) = k)$$

که در آن:

- N تعداد درختان است.
- $h_i(x)$ برچسب پیش‌بینی شده توسط درخت i است.
- k یکی از کلاس‌های ممکن است.
- I تابع نشانگر است که مقدار ۱ می‌گیرد اگر پیش‌بینی با کلاس k مطابقت داشته باشد.

۳.۱. انتخاب تصادفی ویژگی‌ها

یکی از مهم‌ترین جنبه‌های جنگل تصادفی این است که در هر گره، فقط یک زیرمجموعه تصادفی از ویژگی‌ها بررسی می‌شود، نه همه‌ی ویژگی‌ها. این کار باعث افزایش تنوع درختان و کاهش هم‌بستگی بین آن‌ها می‌شود که عملکرد کلی مدل را بهبود می‌بخشد [۱۰].

۲-۲-۳. مزایای جنگل تصادفی

- **دقت بالا:** استفاده از چندین درخت باعث افزایش دقت پیش‌بینی‌ها می‌شود [۱۰].
- **کاهش Overfitting:** ترکیب مدل‌های مختلف منجر به تعمیم بهتر و کاهش بیش‌برازش می‌شود [۱۰].
- **مقیاس‌پذیری:** مدل جنگل تصادفی قابلیت پردازش داده‌های بزرگ را دارد.

- استفاده از داده‌های ناقص: این الگوریتم می‌تواند با داده‌های گمشده به‌طور مؤثری کار کند.
- تشخیص ویژگی‌های مهم: جنگل تصادفی می‌تواند ویژگی‌های تأثیرگذار در پیش‌بینی را شناسایی کند که برای تحلیل اهمیت ویژگی‌ها بسیار مفید است.

۳-۲ XGBoost

۱-۳-۲ مقدمه

XGBoost یک الگوریتم یادگیری ماشین مبتنی بر Gradient Boosting است که برای انجام رگرسیون و طبقه‌بندی با دقت بالا طراحی شده است. این الگوریتم به دلیل سرعت پردازش بالا، دقت عالی و توانایی مقابله با Overfitting، در بسیاری از مسائل کاربردی به‌طور گسترده مورد استفاده قرار می‌گیرد. [۱۱، ۱۵]


۲-۳-۲ ۱. چگونه XGBoost کار می‌کند؟

۱.۱ مدل Gradient Boosting

XGBoost از روش Gradient Boosting برای ساخت مدل استفاده می‌کند. این تکنیک بر اساس یک مجموعه از مدل‌های ضعیف ساخته می‌شود و هر مدل جدید خطاهای مدل قبلی را اصلاح می‌کند. مدل XGBoost با استفاده از مجموعه‌ای از درخت‌های تصمیم‌گیری که به‌صورت تدریجی ساخته می‌شوند، خطای پیش‌بینی را کاهش می‌دهد و پیش‌بینی‌های دقیق‌تری ارائه می‌دهد. [۱۱، ۱۵]

۲.۱ فرآیند یادگیری در XGBoost

۱. مدل با یک پیش‌بینی ساده (مثلاً میانگین مقادیر خروجی) شروع می‌شود.
۲. خطای باقی‌مانده بین خروجی واقعی و پیش‌بینی‌شده محاسبه می‌شود.
۳. یک درخت تصمیم جدید برای پیش‌بینی این خطا ساخته می‌شود.
۴. این فرایند تا زمانی که مدل بهینه شود، تکرار می‌شود.
۵. در نهایت، خروجی‌های همه‌ی درخت‌ها برای تولید پیش‌بینی نهایی ترکیب می‌شوند.



xgboost (آ)

شکل ۲-۳: توضیح مدل XGBoost

۲-۳-۳ چرا XGBoost محبوب است؟

۱.۲ سرعت بالا

XGBoost بهینه‌سازی‌های متعددی برای پردازش سریع دارد، از جمله:

- ساخت درخت‌های تصمیم بهینه
- موازی‌سازی پردازش داده‌ها
- استفاده از حافظه کارآمد برای کاهش زمان پردازش

این ویژگی‌ها موجب افزایش سرعت پردازش و کارایی مدل می‌شود [۱۵].

۲.۲. دقت بالا

XGBoost از Gradient Boosting بهینه‌شده برای کاهش خطا استفاده می‌کند که باعث می‌شود عملکرد بهتری نسبت به روش‌هایی مانند Random Forest و AdaBoost داشته باشد [۱۱].

۳.۲. قابلیت تنظیم فراوان

XGBoost دارای پارامترهای متعددی برای بهینه‌سازی مدل است، از جمله:

- تعداد درخت‌های مدل
- حداکثر عمق هر درخت
- نرخ یادگیری برای کنترل سرعت همگرایی
- تنظیم میزان کاهش خطا برای جلوگیری از شاخه‌زنی‌های غیرضروری

۴.۲. مدیریت خودکار داده‌های گمشده

XGBoost به طور خودکار داده‌های گمشده را مدیریت می‌کند و نیازی به پردازش اضافی داده‌ها برای این موضوع نیست [۱۵].

۵.۲. مقاومت در برابر Overfitting

XGBoost با استفاده از تنظیم Regularization و Pruning از پیچیدگی غیرضروری مدل جلوگیری کرده و دقت پیش‌بینی را افزایش می‌دهد [۱۵].

فصل سوم

فصل سوم بهینه‌سازی ابرپارامترهای MLP به

کمک الگوریتم ژنتیک

۱-۳ MLP: پرسپترون چند لایه

شبکه پرسپترون چند لایه^۱ یک مدل شبکه عصبی^۲ است که شامل لایه‌های ورودی^۳، مخفی^۴ و خروجی^۵ می‌باشد. در این مدل، هر لایه به‌طور کامل به لایه قبلی متصل است و از نورون‌ها^۶ برای پردازش داده‌ها استفاده می‌کند. این مدل یکی از ساده‌ترین و محبوب‌ترین مدل‌ها در یادگیری عمیق است که می‌تواند برای مسائل مختلف پیش‌بینی، دسته‌بندی، و رگرسیون استفاده شود [۱۶].

۱-۱-۳ ساختار شبکه MLP

شبکه MLP معمولاً از سه نوع لایه تشکیل شده است که هرکدام عملکرد خاص خود را دارند:

- **لایه ورودی:** در این لایه داده‌ها وارد مدل می‌شوند. تعداد نورون‌های این لایه برابر با تعداد ویژگی‌های ورودی است. به عبارت دیگر، اگر داده‌های ورودی دارای d ویژگی باشند، لایه ورودی شامل d نورون خواهد بود.
- **لایه‌های مخفی:** این لایه‌ها پردازش‌های غیرخطی را روی ورودی‌ها انجام می‌دهند. تعداد و اندازه این لایه‌ها تأثیر زیادی بر عملکرد مدل دارند. هر نورون در این لایه به نورون‌های لایه قبلی متصل است و معمولاً از تابع فعال‌سازی غیرخطی برای پردازش داده‌ها استفاده می‌کند.
- **لایه خروجی:** در این لایه، پیش‌بینی مدل انجام می‌شود. تعداد نورون‌ها در این لایه بستگی به تعداد کلاس‌های خروجی^۷ یا ابعاد پیش‌بینی دارد. برای مثال، در مسائل دسته‌بندی باینری، این لایه شامل یک نورون است؛ در حالی که در مسائل چندکلاسی تعداد نورون‌ها برابر با تعداد کلاس‌ها می‌شود.

¹MLP

²Neural Network


³Input Layer

⁴Hidden Layers

⁵Output Layer

⁶Neurons

⁷Output Classes



(آ) ساختار کلی شبکه MLP

شکل ۳-۱: شرح ساختار شبکه MLP

۳-۱-۲ فرآیند یادگیری در MLP

در فرآیند یادگیری MLP، وزن‌ها^۸ و بایاس‌ها^۹ با استفاده از الگوریتم Backpropagation به‌طور تدریجی بهینه می‌شوند [۱۷]. این فرآیند شامل مراحل زیر است:

- **محاسبه خطا:** ابتدا مدل پیش‌بینی را انجام می‌دهد و سپس خطا بین پیش‌بینی‌ها و مقادیر واقعی محاسبه می‌شود. این خطا به‌صورت تفاوت بین پیش‌بینی مدل ($\hat{y}$) و مقدار واقعی (y) بیان می‌شود:

$$E = \frac{1}{2} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

در این معادله، E خطای کلی و n تعداد نمونه‌ها است.

- **پخش خطا به عقب:** با استفاده از الگوریتم Backpropagation، خطا به‌طور معکوس از لایه‌های خروجی به لایه‌های مخفی ارسال می‌شود. این الگوریتم به کمک قاعده زنجیره‌ای^{۱۰} مشتقات را محاسبه کرده و آن‌ها را برای به‌روزرسانی وزن‌ها استفاده می‌کند. به‌طور خاص، تغییرات وزن‌ها

^۸Weights

^۹Biases

^{۱۰}Chain Rule

در لایه k به صورت زیر محاسبه می‌شود:

$$\Delta w_{jk} = -\eta \cdot \frac{\partial E}{\partial w_{jk}}$$

که در آن w_{jk} وزن بین نورون j در لایه l و نورون k در لایه $l + 1$ و η نرخ یادگیری است.

- **به‌روزرسانی وزن‌ها:** وزن‌ها به‌طور تدریجی با استفاده از روش بهینه‌سازی مانند Gradient Descent به‌روزرسانی می‌شوند:

$$w_{jk}^{new} = w_{jk} - \eta \cdot \frac{\partial E}{\partial w_{jk}}$$

که در آن w_{jk}^{new} وزن به‌روزشده است.


۳-۱-۳ تابع فعال‌سازی ReLU

تابع فعال‌سازی ReLU یکی از متداول‌ترین توابع فعال‌سازی است که در لایه‌های مخفی شبکه‌های عصبی استفاده می‌شود. این تابع مقادیر منفی ورودی را به صفر تبدیل می‌کند و مقادیر مثبت را بدون تغییر عبور می‌دهد؛ بدین ترتیب مشکل کاهش گرادیان که در توابعی مانند sigmoid یا tanh دیده می‌شود، کاهش می‌یابد. [۱۸، ۱۹]

$$f(x) = \max(0, x)$$

۴-۱-۳ مزایای ReLU

- ReLU به طور معمول از توابع دیگر فعال‌سازی سریع‌تر است.
- استفاده از ReLU باعث می‌شود شبکه‌های عصبی سریع‌تر یاد بگیرند، زیرا مشکل کاهش گرادیان کمتر رخ می‌دهد.
- محاسبات این تابع نسبت به توابع دیگر ساده‌تر است.



(آ) تابع فعال‌سازی ReLU

شکل ۳-۲: شرح تابع فعال‌سازی ReLU

چالش‌ها

- ReLU در مقادیر منفی ورودی همیشه خروجی صفر می‌دهد که ممکن است به مشکل مردن نورون‌ها^{۱۱} منجر شود.

¹¹Dying Neurons

۲-۳ الگوریتم ژنتیک

الگوریتم ژنتیک یک روش جستجو و بهینه‌سازی است که بر اساس اصول تکامل بیولوژیکی مانند انتخاب طبیعی، جهش، ترکیب ژن‌ها و انتخاب نسل‌های برتر عمل می‌کند. این الگوریتم برای حل مسائلی که فضای حالت آن‌ها بسیار بزرگ و پیچیده است، بسیار مناسب می‌باشد. در این مطالعه، الگوریتم ژنتیک برای بهینه‌سازی ابرپارامترهای مدل MLP به کار رفته است. [۲۰، ۲۱]

۱-۲-۳ مفاهیم پایه‌ای الگوریتم ژنتیک

الگوریتم ژنتیک ابتدا یک جمعیت از راه‌حل‌ها ایجاد می‌کند که هر راه‌حل نمایانگر یک ترکیب از ابرپارامترهای مدل MLP است. این جمعیت به صورت تصادفی ایجاد شده و در هر نسل تحت فرآیندهایی مانند انتخاب، ترکیب و جهش قرار می‌گیرد تا بهترین ترکیب ابرپارامترها استخراج شود. [۲۰، ۲۱]

- **انتخاب:** اعضای جمعیت بر اساس عملکرد (مثلاً دقت) انتخاب می‌شوند.
- **ترکیب^{۱۲}:** ابرپارامترهای دو عضو از جمعیت با هم ترکیب شده و ترکیب جدیدی تولید می‌شود.
- **جهش^{۱۳}:** در این مرحله، ابرپارامترهای یک فرد به طور تصادفی تغییر می‌کنند تا از گیر کردن در بهینه‌های محلی جلوگیری شود.

۲-۲-۳ فضای حالت

فضای حالت در الگوریتم ژنتیک به مجموعه تمامی ترکیب‌های ممکن از ابرپارامترهای مدل MLP اطلاق می‌شود. این فضای حالت ممکن است شامل موارد زیر باشد:

- **تعداد لایه‌های مخفی:** تعداد لایه‌های مخفی شبکه که از ۱ تا ۱۰ قابل تغییر است.
- **تعداد نوروها در هر لایه:** تعداد نوروها در هر لایه که در بازه‌ای مشخص (بین ۱۰ تا ۲۰۰) تنظیم می‌شوند.
- **نرخ یادگیری:** سرعت به‌روزرسانی وزن‌ها در فرآیند آموزش.
- **تابع فعال‌سازی:** شامل توابع فعال‌سازی مانند sigmoid، ReLU و tanh.

¹²Crossover

¹³Mutation

- ویژگی‌ها: مجموعه ویژگی‌های ورودی که به‌طور تصادفی انتخاب می‌شوند.

[۱۸، ۱۷، ۱۶]

۳-۲-۳ پارامترهای الگوریتم ژنتیک


برای بهینه‌سازی ابرپارامترها، الگوریتم ژنتیک از پارامترهای زیر استفاده می‌کند:

- **تعداد نسل‌ها:** تعداد دفعاتی که الگوریتم تکرار می‌شود. در این مطالعه، تعداد نسل‌ها برابر با ۵۰ در نظر گرفته شده است.
- **اندازه جمعیت:** تعداد راه‌حل‌های موجود در هر نسل، در اینجا ۳۰.
- **نرخ جهش:** درصد تغییرات تصادفی اعمال شده روی ابرپارامترها.
- **عملکرد انتخاب:** استفاده از روش‌هایی مانند Selection Tournament برای انتخاب بهترین‌ها.

[۲۰، ۲۱]

۴-۲-۳ عملکرد الگوریتم ژنتیک

ابتدا یک جمعیت تصادفی از ترکیب‌های ابرپارامترها ایجاد می‌شود. سپس در هر نسل، فرآیندهای انتخاب، ترکیب و جهش برای هر فرد اجرا می‌شود. این فرآیندها به‌طور تکراری در طول ۵۰ نسل انجام می‌شود تا بهترین ترکیب ابرپارامترها استخراج و به مدل MLP اعمال شود.



شکل ۳-۳: نمودار مراحل الگوریتم ژنتیک

فصل چهارم

فصل چهارم نتایج عددی

۱-۴ نتایج عددی و مقایسه روش ها

۱-۱-۴ مجموعه داده‌گان

این دیتاست که شامل اطلاعات دقیقی درباره عوامل خطر بیماری‌های قلبی عروقی^(۱) است، با جستجوی Kaggle در سایت Adults in Disease Cardiovascular for Factors Risk Exploring به دست آمده است. آدرس دیتاست شامل ۷۰,۰۰۰ نمونه با ۱۳ ویژگی است که به شرح زیر می‌باشند:

- id: شناسه یکتای هر نمونه
- age: سن فرد
- gender: جنسیت فرد
- height: قد فرد
- weight: وزن فرد
- ap_hi: فشار خون سیستولیک
- ap_lo: فشار خون دیاستولیک
- cholesterol: سطح کلسترول
- gluc: سطح گلوکز
- smoke: وضعیت مصرف سیگار
- alco: وضعیت مصرف الکل
- active: میزان فعالیت فیزیکی
- cardio: وضعیت بیماری قلبی عروقی

تمامی ستون‌ها بدون مقدار null هستند و حجم کل دیتاست حدود ۶/۹ مگابایت است. این دیتاست به عنوان منبعی عالی برای محققان در جهت ادغام تکنیک‌های مختلف یادگیری ماشین^(۲)، یادگیری

¹Cardiovascular Diseases - CVD

²Machine Learning - ML

عمیق (۳) و هوش مصنوعی (۴) برای کشف روابط بالقوه بین عوامل خطر بیماری‌های قلبی عروقی و بیماری‌های قلبی عروقی دیده می‌شود که در نهایت می‌تواند به درک بهتر عوامل خطر بیماری‌های قلبی عروقی و طراحی اقدامات پیشگیرانه بهتر منجر شود. به همین دلیل، این دیتاست به عنوان یک قطب‌نما برای تعیین گزینه‌های درمانی مناسب به دلیل تشخیص زودهنگام بیماری‌های قلبی عروقی استفاده شده است.

۴-۱-۲ معیارهای ارزیابی مدل‌ها

در این مطالعه، عملکرد مدل‌های مختلف یادگیری ماشین با استفاده از معیارهای زیر ارزیابی شده است:

- **دقت (Accuracy):** نشان‌دهنده نسبت نمونه‌های صحیح پیش‌بینی‌شده به کل نمونه‌ها است و معیار کلی برای عملکرد مدل محسوب می‌شود.
- **مساحت زیر منحنی مشخصه عملکرد گیرنده (AUC-ROC):** بیانگر توانایی مدل در تمایز بین کلاس‌های مختلف است. مقدار بالاتر نشان‌دهنده عملکرد بهتر مدل در تفکیک نمونه‌های مثبت و منفی است.
- **امتیاز F1-Score:** میانگین هارمونیک Precision و Recall است که برای داده‌های نامتوازن اهمیت ویژه‌ای دارد.

۴-۱-۳ تشریح گام‌به‌گام روش پیشنهادی

در این بخش، روش پیشنهادی برای بهینه‌سازی ابرپارامترهای یک شبکه عصبی چندلایه با استفاده از الگوریتم ژنتیک تشریح می‌شود.

مرحله اول: آماده‌سازی داده‌ها

در ابتدا، داده‌ها نرمال‌سازی شدند تا عملکرد مدل بهبود یابد. برای داده‌های عددی، نرمال‌سازی به روش Standardization انجام شد که مقدار هر ویژگی را بر اساس میانگین و انحراف معیار مقیاس‌بندی می‌کند:

³Deep Learning - DL

⁴Artificial Intelligence - AI

$$X_{standard} = \frac{X - \mu}{\sigma} \quad (۱-۴)$$

که در آن:

• μ میانگین داده‌ها است.

• σ انحراف معیار داده‌ها است.

این فرایند باعث می‌شود که داده‌ها دارای میانگین صفر و واریانس واحد باشند، که معمولاً برای مدل‌های یادگیری ماشین مفیدتر است. همچنین، این روش در صورتی که ویژگی‌ها دارای مقیاس‌های متفاوت باشند، باعث بهبود پایداری مدل و تسریع همگرایی می‌شود.

انتخاب ویژگی‌ها و بهینه‌سازی ابرپارامترهای شبکه عصبی

برای کاهش ابعاد داده و بهبود کارایی مدل، از الگوریتم ژنتیک به صورت هم‌زمان برای انتخاب ویژگی‌ها و بهینه‌سازی ابرپارامترها استفاده شد. در این فرآیند، هر کروموزوم نمایانگر ترکیبی از ویژگی‌های انتخاب‌شده و مقادیر مربوط به ابرپارامترهای شبکه عصبی بود. تابع هزینه^۵ بر مبنای دقت مدل طبقه‌بندی ارزیابی شد.

ویژگی‌های انتخاب‌شده برای مدل نهایی عبارتند از:

• gender: جنسیت فرد

• weight: وزن فرد

• ap_hi: فشار خون سیستولیک

• cholesterol: سطح کلسترول

• smoke: وضعیت مصرف سیگار

• active: میزان فعالیت فیزیکی

^۵Fitness Function

• blood_pressure: فشار خون

مقادیر بهینه‌شده برای پارامترهای زیر توسط الگوریتم ژنتیک تعیین گردید:

• نرخ یادگیری^۶

• تعداد لایه‌های پنهان^۷

• تعداد نورون‌های هر لایه^۸

• تابع فعال‌سازی^۹

برای شروع فرایند بهینه‌سازی، جمعیت اولیه شامل ۳۰ کروموزوم در نظر گرفته شد و الگوریتم ژنتیک برای ۵۰ نسل اجرا شد. هر مدل در هر نسل به مدت ۱۰۰ دوره^{۱۰} آموزش داده شد. مقادیر نهایی به دست آمده برای بهترین ترکیب ابرپارامترها به صورت زیر بودند:

• تعداد لایه‌های پنهان: ۱۰ لایه

• تعداد نورون‌های هر لایه: {۳۵، ۷، ۱۵۷، ۱۷۶، ۲۶، ۱۵۱، ۱۵۱، ۱۲، ۸۳، ۳۰}

• تابع فعال‌سازی: ReLU

• نرخ یادگیری: ۰/۰۰۷۷۰۹۱۲۷۴۵۳۳۰۸۷۱۶

• تعداد نسل‌ها: ۵۰

• اندازه جمعیت: ۳۰

• دقت نهایی مدل: ۷۳/۴٪

مقایسه نتایج با تنظیمات دیگر

در جدول زیر، چند نمونه دیگر از تنظیمات ابرپارامترها که توسط الگوریتم ژنتیک تولید شده‌اند، همراه با دقت مدل آورده شده است:

^۶Learning Rate

^۷Hidden Layers

^۸Neurons per Layer

^۹Activation Function

^{۱۰}Epochs

تعداد لایه‌ها	نورون‌ها در هر لایه	تابع فعال‌سازی	نرخ یادگیری	ویژگی‌های انتخاب‌شده	دقت (%)
۱۰	۲۶، ۱۷۶، ۱۵۷، ۷، ۳۵، ۸۳، ۱۲، ۱۵۱، ۱۵۱، ۳۰	ReLU	۰/۰۰۷۷	gender, ap_hi, weight, cholesterol, active, smoke, blood_pressure	۷۳/۴
۸	۱۲۰، ۱۰۰، ۱۵، ۲۰، ۲۵، ۹۰، ۸۰، ۵۰	Sigmoid	۰/۰۰۵۲	height, gender, ap_hi, weight, smoke gluc,	۶۸/۹
۱۲	۱۴۰، ۱۲۰، ۱۰، ۴۰، ۳۰، ۱۱۰، ۱۰۰، ۶۰، ۱۵، ۲۰، ۲۵، ۵۰	Tanh	۰/۰۰۹۳	gender, ap_lo, weight, cholesterol, cardio active,	۷۱/۲
۶	۴۵، ۹۰، ۷۵، ۱۰، ۱۵، ۳۰	ReLU	۰/۰۰۶۸	height, gender, ap_lo, ap_hi, smoke cholesterol,	۶۶/۵
۹	۱۶۰، ۱۴۰، ۱۲، ۳۰، ۱۰، ۱۲۰، ۱۳۰، ۳۵، ۷۰	ReLU Leaky	۰/۰۰۸۱	weight, gender, gluc, ap_hi, active	۷۰/۵

جدول ۴-۱: مقایسه تنظیمات مختلف ابرپارامترها و تأثیر آن بر دقت مدل

ارزیابی نهایی مدل

پس از اجرای الگوریتم ژنتیک، بهترین مجموعه ابرپارامترها استخراج شد و مدل نهایی با این مقادیر به مدت ۲۰۰۰ دوره بر روی داده‌های آموزش دیده شده تست گردید.

۴-۱-۴ مقایسه عددی و تحلیل نتایج

در جدول زیر، عملکرد مدل‌های مختلف مقایسه شده است:

جدول ۴-۲: مقایسه عملکرد مدل‌های مختلف در پیش‌بینی CVD

مدل	دقت (Accuracy)	AUC-ROC	F1-Score
Decision Tree	۶۲/۹٪	۶۳٪	۶۳٪
Random Forest	۷۱٪	۷۷/۳٪	۷۲٪
XGBoost	۷۳/۹٪	۸۰/۳٪	۷۵٪
MLP (بهینه‌شده با الگوریتم ژنتیک)	۷۳/۴٪	۷۸٪	۷۲٪

همان‌طور که مشاهده می‌شود، مدل XGBoost و MLP عملکرد بهتری نسبت به سایر روش‌ها دارند. مدل درخت تصمیم کمترین دقت را داشته و جنگل تصادفی بهبود قابل توجهی نسبت به آن نشان داده است.

فصل پنجم

جمع‌بندی و نتیجه‌گیری و پیشنهادات

۱-۵ نتیجه‌گیری

در این مطالعه، ما به بررسی و مقایسه الگوریتم‌های مختلف یادگیری ماشین و یادگیری عمیق برای پیش‌بینی بیماری‌های قلبی عروقی پرداختیم. نتایج نشان داد که مدل‌های XGBoost و MLP بهینه‌شده با الگوریتم ژنتیک عملکرد بهتری نسبت به سایر روش‌ها دارند. این مدل‌ها توانستند دقت بالاتری در پیش‌بینی بیماری‌های قلبی عروقی ارائه دهند و نشان دادند که استفاده از تکنیک‌های بهینه‌سازی می‌تواند بهبود قابل توجهی در عملکرد مدل‌ها ایجاد کند.

مدل XGBoost به دلیل سرعت پردازش بالا و دقت عالی، به عنوان یکی از بهترین الگوریتم‌ها در این مطالعه شناخته شد. همچنین، استفاده از الگوریتم ژنتیک برای بهینه‌سازی ابرپارامترهای MLP نشان داد که این روش می‌تواند به بهبود عملکرد مدل‌های یادگیری عمیق کمک کند. این نتایج نشان‌دهنده اهمیت بهینه‌سازی ابرپارامترها و استفاده از تکنیک‌های پیشرفته در بهبود دقت پیش‌بینی مدل‌ها است.

۲-۵ پیشنهادات

با توجه به نتایج به‌دست‌آمده، پیشنهادات زیر برای تحقیقات آینده ارائه می‌شود:

- **استفاده از داده‌های بیشتر و متنوع‌تر:** برای بهبود دقت مدل‌ها، استفاده از مجموعه داده‌های بزرگ‌تر و متنوع‌تر می‌تواند مفید باشد. این کار می‌تواند به مدل‌ها کمک کند تا الگوهای پیچیده‌تری را شناسایی کنند و دقت پیش‌بینی را افزایش دهند.
- **بررسی تکنیک‌های جدید یادگیری ماشین:** با توجه به پیشرفت‌های سریع در حوزه یادگیری ماشین، بررسی و استفاده از تکنیک‌های جدیدتر می‌تواند به بهبود عملکرد مدل‌ها کمک کند.
- **استفاده از روش‌های هوش مصنوعی قابل توضیح:** برای درک بهتر تصمیمات مدل‌ها و افزایش اعتماد به نتایج، استفاده از روش‌های هوش مصنوعی قابل توضیح مانند SHAP می‌تواند مفید باشد.
- **بهینه‌سازی بیشتر مدل‌ها:** استفاده از تکنیک‌های بهینه‌سازی پیشرفته‌تر مانند Bayesian Optimization می‌تواند به بهبود عملکرد مدل‌ها کمک کند.
- **توسعه سیستم‌های پشتیبان تصمیم‌گیری:** با استفاده از مدل‌های پیش‌بینی دقیق، می‌توان

سیستم‌های پشتیبان تصمیم‌گیری برای پزشکان و متخصصان بهداشت و درمان توسعه داد که به تشخیص زودهنگام و درمان بهتر بیماری‌های قلبی عروقی کمک کند.

• **تحلیل عمیق‌تر ویژگی‌ها:** استفاده از روش‌های تحلیل ویژگی برای شناسایی و درک بهتر عوامل خطر اصلی می‌تواند به بهبود مدل‌ها و ارائه توصیه‌های دقیق‌تر کمک کند.

منابع و مراجع

- [1] Organization, World Health. Cardiovascular diseases (cvds). World Health Organization, 2021.
- [2] Dawber, T. R., Meadors, G. F., and Moore, F. E. Epidemiological approaches to heart disease: The framingham study. *International Journal of Epidemiology*, 44(6):1800–1813, 2015.
- [3] Alaref, Jamil, Smedby, Örjan, Sandborg, Michael, and Persson, Anders. Artificial intelligence in cardiac imaging: A review of applications and challenges. *Journal of the American College of Cardiology*, 71(23):2663–2674, 2018.
- [4] Ghosh, Rituparna, Biswas, Ranjit, and Sarkar, Anirban. Machine learning in cardiovascular diseases: A review. *Journal of Healthcare Engineering*, 2021:1–20, 2021.
- [5] Aryal, Shrawan Kumar, Alimadadi, Ali, Manandhar, Isha, Joe, Benjamin, Cheng, Xiaolian, and Yang, Xiaowei. Microbiome and its role in cardiovascular diseases. *Journal of the American Heart Association*, 9(11):e014614, 2020.
- [6] Lundberg, Scott M. and Lee, Su-In. A unified approach to interpreting model predictions. *Advances in Neural Information Processing Systems*, 30:4765–4774, 2017.
- [7] Quinlan, J. R. Induction of decision trees. *Machine Learning*, 1(1):81–106, 1986.
- [8] Breiman, L., Friedman, J. H., Olshen, R. A., and Stone, C. J. *Classification and Regression Trees*. Wadsworth International Group, California, 1984.

- [9] Quinlan, J. R. C4.5: Programs for Machine Learning. Morgan Kaufmann, San Mateo, CA, 1993.
- [10] Breiman, L. Random forests. *Machine Learning*, 45(1):5–32, 2001.
- [11] Friedman, J. H. Greedy function approximation: A gradient boosting machine. *Annals of Statistics*, 29(5):1189–1232, 2001.
- [12] Dietterich, T. G. Ensemble methods in machine learning. *Multiple Classifier Systems*, pp. 1–15, 2000.
- [13] Breiman, L. Bagging predictors. *Machine Learning*, 24(2):123–140, 1996.
- [14] Efron, B. Bootstrap methods: Another look at the jackknife. *The Annals of Statistics*, 7(1):1–26, 1979.
- [15] Chen, T. and Guestrin, C. Xgboost: A scalable tree boosting system. in *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pp. 785–794. ACM, 2016.
- [16] Haykin, Simon. *Neural Networks: A Comprehensive Foundation*. Prentice Hall, Englewood Cliffs, NJ, 1999.
- [17] Rumelhart, David E., Hinton, Geoffrey E., and Williams, Ronald J. Learning representations by back-propagating errors. *Nature*, 323(6088):533–536, 1986.
- [18] Nair, Vinod and Hinton, Geoffrey E. Rectified linear units improve restricted boltzmann machines. in *Proceedings of the 27th International Conference on Machine Learning (ICML-10)*, pp. 807–814, 2010.
- [19] Glorot, Xavier, Bordes, Antoine, and Bengio, Yoshua. Deep sparse rectifier neural networks. *Proceedings of the 14th International Conference on Artificial Intelligence and Statistics*, pp. 315–323, 2011.

- [20] Goldberg, David E. Genetic Algorithms in Search, Optimization, and Machine Learning. Addison-Wesley, Reading, MA, 1989.
- [21] Mitchell, Melanie. An Introduction to Genetic Algorithms. MIT Press, Cambridge, MA, 1996.

Abstract

In this project, we have focused on evaluating and improving the performance of machine learning models on a cardiovascular disease (CVD) dataset. Previously, models such as Tree Decision, Forest Random, and XGBoost were applied to this dataset. The aim of this project was to implement a MLP (Multilayer Perceptron) model and optimize its hyperparameters using a genetic algorithm. The results indicate that hyperparameter optimization using a genetic algorithm can enhance the performance of the MLP model in predicting cardiovascular diseases.

Key Words:

Machine Learning, Cardiovascular Disease, MLP, XGBoost, Genetic Algorithm